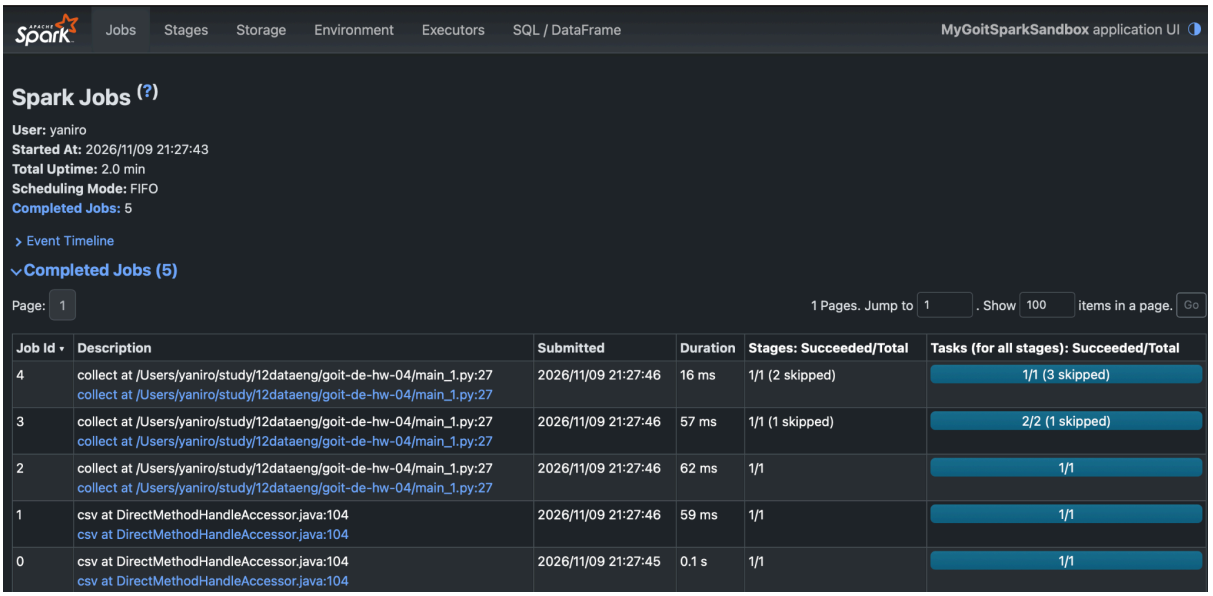
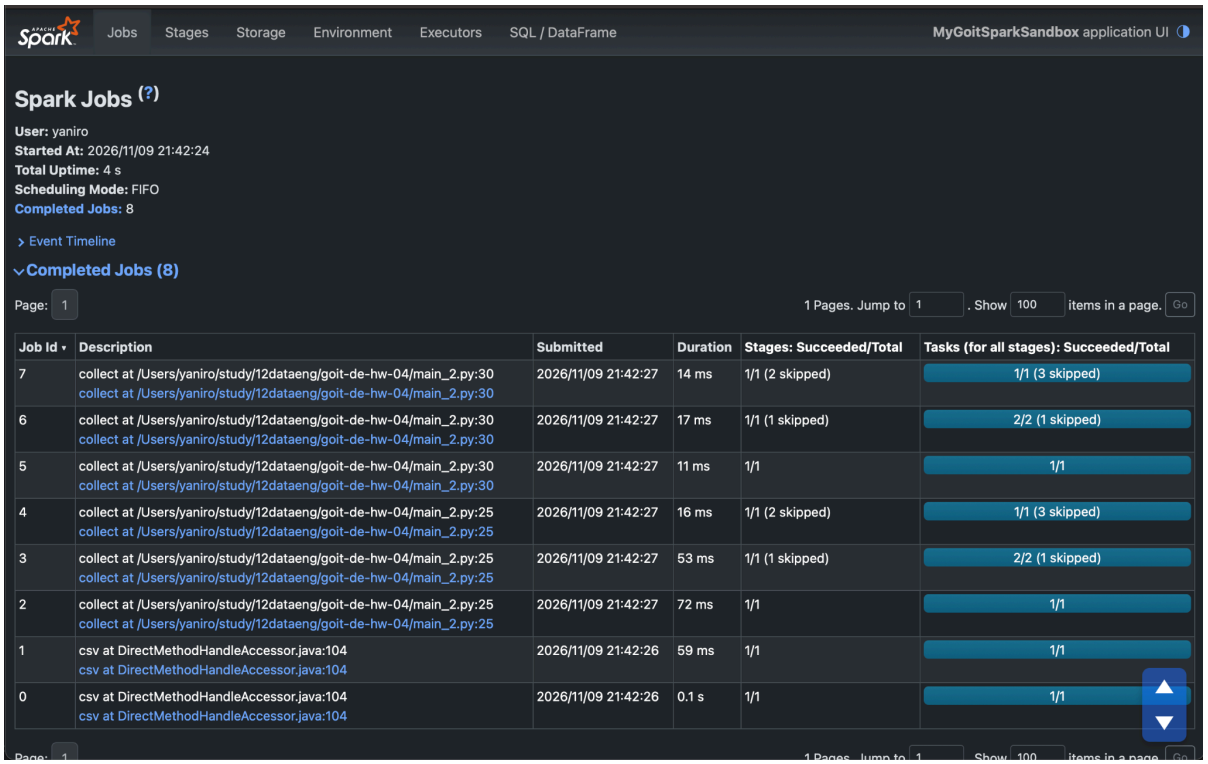
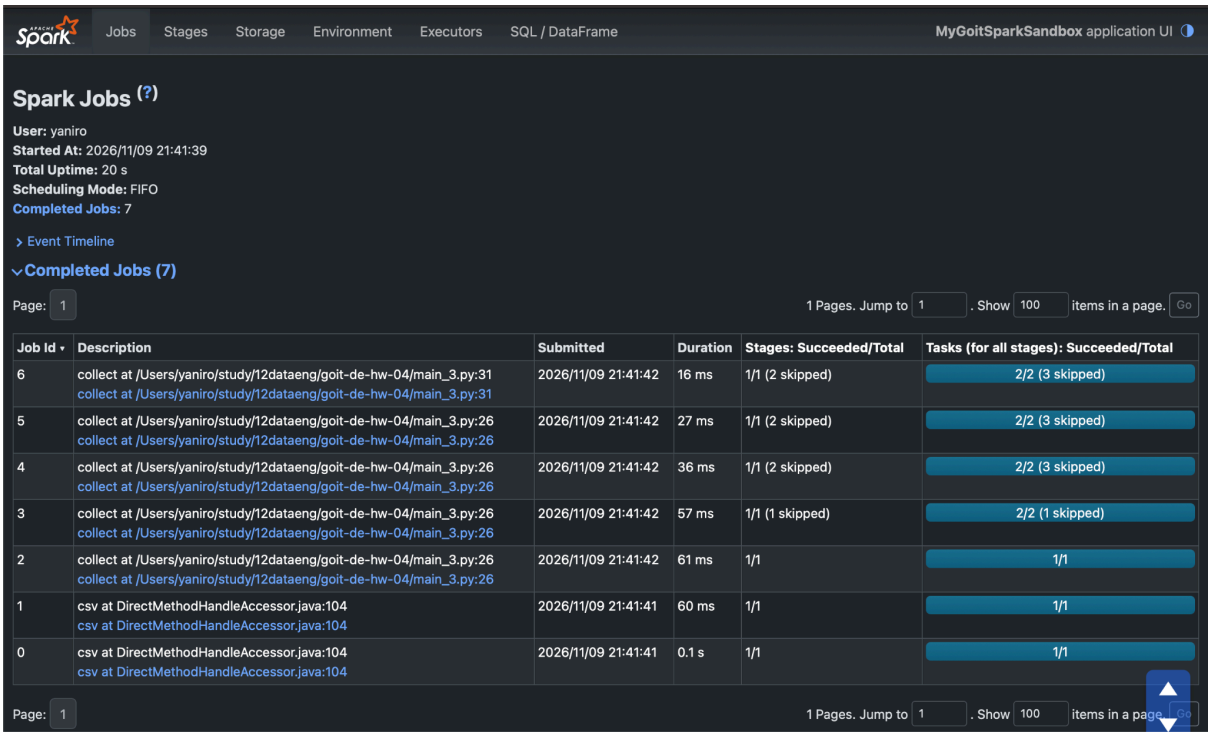


На першому скріншоті з базової версії коду модна побачити 5 spark jobs: 2 для прочитання csv файлу та визначення схеми (infer schema = true), та 3 jobs для термінальної операції collect() розділені через repartition(2) та groupBy.



На другому скріншоті стало 8 spark job, оскільки для виконання другої термінальної операції collect повторно виконуються ті ж операції repartition(2) та groupBy, які повторно генерують 3 етапи виконання



На третьому скріншоті з доданими кешуванням стало на одну spark job менше, оскільки результат repartition(2) та groupBy перевикористовується для двох операцій collect() з доданою операцією фільтрування(where) для другого collect()